

Estruturas de Dados

Hash Tables



2021/2022

Hash Tables

- As árvores binárias de pesquisa são vocacionadas para o armazenamento de informação ordenada.
- Uma *hash table* é uma estrutura de dados que pode ser usada quando a ordem da informação não é relevante
 - Inserções, procuras e remoções são feitas em tempo médio constante!



Hash Table - Introdução

- **Introdução (exemplo):**
 - Vamos assumir que estamos a trabalhar com um conjunto de números inteiros positivos pequenos (entre 0 e 65535)
 - Para guardar um conjunto destes números, podemos usar um *array* *a* com um número correspondente de posições inicializadas a 0.
 - As operações básicas podem ser implementadas de forma muito simples e eficaz:
 - *Inserção(i):* $a[i]++$;
 - *Remoção(i):* $a[i]--$;
 - *Pesquisa(i):* $a[i] \neq 0$



Hash Table - Introdução

- **Introdução (exemplo):**
 - Quais é que são os problemas desta solução?
 - *Se usássemos números de 32 bits era necessária uma tabela com 4 G entradas ...*
 - *Nem todos os dados são de natureza numérica (strings?)...*



Hash Table - Introdução

- Nem todos os dados são de natureza numérica??
 - Nem por isso... Toda a informação é armazenada por *bits* que podem ser interpretados numericamente.
 - P.ex:
 - Cada caracter corresponde a 7 bits (código ASCII). Por isso, uma string pode ser interpretada como um número em base $2^7=128$ da seguinte forma:

$$\text{"Ola"} = 79 * 2^{14} + 108 * 2^7 + 97 * 2^0 = 1308257$$

↑
'O'

↑
'l'

↑
'a'



Hash Table - Introdução

- Um problema da abordagem anterior é que os números necessários para representar as strings são enormes:
 - Uma string de N caracteres é representada por um número com $N \times 7$ bits.
 - Para strings com 10 caracteres seriam necessários número com 70 bits!
 - Ou seja, uma tabela de dimensão 2^{70}
 - O que é muito,... mas mesmo muito, grande (1 Tera = 2^{40}).
 - É necessário contornar esta dificuldade adicional...



Hash Table - Introdução

- A ideia é encontrar uma função que transforma os dados em números de dimensão mais reduzida...
 - Qualquer função deste género é denominada por ***função de hash*** (ou função de escrutínio).
 - Se uma função de *hash* mapear os dados em inteiros entre 0 e $X-1$, um *array* com dimensão X será suficiente.



Hash Table - Introdução

- Uma forma básica de mapear qualquer inteiro N para a gama $[0, X[$ é obter o resto da divisão de N por X , ou seja
 - $H(N, X) = N \bmod X$
- *Uma possibilidade que surge consiste então em usar o modulo para obter, a partir do número grande, o índice desejado. Por exemplo:*

$$H(\text{"Ola"}, 1024) = 1308257 \bmod 1024 = 609$$

*Insertão("Ola") $\Rightarrow$
 $a[H(\text{"Ola"}, 1024)]++;$*



Hash Table - Introdução

- Como é obvio, há agora um novo problema a resolver:
 - Existe a possibilidade de ocorrerem colisões, ou seja, strings diferentes que são mapeadas para o mesmo índice...
 - Ex:

$$\text{"La"} = 76 * 2^7 + 97 * 2^0 = 9825$$

$$H(\text{"La"}, 1024) = 609$$

Logo "La" e "Ola" correspondem ao mesmo índice... E agora?



Hash Table - Introdução

- As colisões são inevitáveis, mas há várias formas de lidar com elas.
- Vamos analisar três delas:
 - Sondagem linear
 - Sondagem quadrática
 - Encadeamento



Funções de Hash

- Uma propriedade da função de *hash* é que deve ser simples (e rápida) de calcular.
- A função apresentada anteriormente não o é...
 - Os resultados intermédios podem fazer *overflow*...
 - Para uma string com 10 dígitos, precisamos de uma fórmula com o termo 2^{70} ... Como é que vamos lidar com isso?



Funções de Hash

- Sabendo que:

$$79 * 2^{14} + 108 * 2^7 + 97 * 2^0 = ((79 * 2^7 + 108) * 2^7 + 97)$$

- Ou, de forma genérica:

$$A_3 X^3 + A_2 X^2 + A_1 X^1 + A_0 X^0 = (((A_3)X + A_2)X + A_1)X + A_0$$

O cálculo pode ser feito iterativamente através de uma expressão com a forma $aX + A$ (evita-se o uso de X^n)

$$a_2 = A_3 X + A_2$$

$$a_1 = a_2 X + A_1$$

$$a_0 = a_1 X + A_0$$



Funções de Hash

- Os resultados intermédios (e final) ainda podem fazer *overflow*...
- Dado que apenas nos interessa o módulo, podemos aplicar essa operação após cada passo intermédio para reduzir a dimensão dos resultados intermédios.

$$a_n = (a_{n+1}X + A_n) \bmod M$$



Funções de Hash

```
// função de hash aceitável
public static int hash( String key, int tableSize )
{
    int hashVal = 0;
    for( int i = 0; i < key.length( ); i++ )
        hashVal = ( hashVal * 128 + key.charAt( i ) ) % tableSize;
    return hashval;
}
```

- Uma deficiência desta função é que a operação % é demorada...
- Outro problema é que a multiplicação por 128 roda os primeiros caracteres para a esquerda (parte mais significativa do resultado), pelo que serão tipicamente cortados pela operação de módulo, não tendo qualquer impacto no resultado final.



Funções de Hash

- Como resolver o primeiro problema (custo de tempo da operação %)?

- Permite-se o *overflow* natural das operações, fazendo-se um único % no final. Neste caso, deve-se ter em atenção que um *overflow* pode gerar resultado negativos.

- O resultado não é o mesmo da função anterior, mas isso não é relevante!

```
// função de hash aceitável - 2ª versão
public static int hash( String key, int tableSize )
{
    int hashVal = 0;
    for( int i = 0; i < key.length( ); i++ )
        hashVal = ( hashVal * 128 + key.charAt( i ) );
    return hashval % tableSize;
}
```



Funções de Hash


• **Como resolver o segundo problema (perda de informação em relação aos *bits* de mais significativos)?**

- Multiplicam-se os resultados intermédios não por 128, mas sim por outro número que não efectua uma rotação perfeita. 37 é uma boa escolha.
- Isto significa que os primeiros caracteres considerados não serão rodados tão depressa para a parte mais significativa do resultado (e dessa forma terão mais (algum) impacto no resultado final).



Funções de Hash

- Exemplo: Multiplicação por uma potência de 2: 32 (100000 b)



Funções de Hash

- Exemplo: Multiplicação por 37 (100101b)

$$\begin{array}{r}
 b_6 b_5 b_4 b_3 b_2 b_1 b_0 \\
 \times \quad 100101_b \\
 \hline
 b_6 b_5 b_4 b_3 b_2 b_1 b_0 \\
 0000000 \\
 b_6 b_5 b_4 b_3 b_2 b_1 b_0 \\
 0000000 \\
 + \quad 0000000 \\
 \hline
 b_6 b_5 b_4 b_3 b_2 b_1 b_0
 \end{array}$$

$T(r_x)$ é dependente das mesmas variáveis que r_x

O valor de r_3 é uma função de (depende de) todos os primeiros 4 bits.

E assim sucessivamente..

$$r_6 = b_6 + b_4 + b_1 + T(r_5)$$

$$r_5 = b_5 + b_3 + b_0 + T(r_4)$$

$$r_4 = b_4 + b_2 + T(r_3)$$

$$r_0 = b_0$$

$$r_1 = b_1$$

$$r_2 = b_2 + b_0$$

$$r_3 = b_3 + b_1 + T(r_2)$$

$$b_3 + b_1 + b_2 b_0 =$$

$$F(b_3, b_2, b_1, b_0)$$

transporte



Funções de Hash

- Função de hash - Final

```
//função de hash - versão final
public static int hash( String key, int tableSize )
{
    int hashVal = 0;
    for( int i = 0; i < key.length( ); i++ )
        hashVal = 37 * hashVal + key.charAt( i );
    hashVal %= tableSize;
    if( hashVal < 0 )
        hashVal += tableSize;
    return hashVal;
}
```



Funções de Hash

- A velocidade da função de hash é importante, mas não é o único critério:

```
public static int hash(String key, int tableSize)
{
    int hashVal = 0;
    for( int i =0; i < key.length( ); i++ )
        hashVal += key.charAt( i );
    return hashVal % tableSize;
}
```

- Esta função é rápida, mas é má, porque não distribui equitativamente os índices gerados pela gama disponível.
 - *O valor da chave irá concentrar-se perto do valor médio esperado (número de caracteres* valor médio de um caracter), provocando um grande número de colisões.*
 - *Esta tendência acentua-se com o aumento da dimensão da string.*



Colisões - Sondagem Linear

- O que fazer quando há uma colisão?
 - Mesmo que as chaves estejam bem distribuídas, as colisões são inevitáveis.
 - Dessa forma, o que fazer se a posição indicada já se encontra ocupada (presumivelmente por outra *string*)?



Colisões - Sondagem Linear

- A estratégia mais simples consiste em pesquisar sequencialmente o *array* a partir da posição original até que seja encontrada uma posição livre.
 - Esta pesquisa dá a volta do final para o início do *array* se necessário.



Colisões - Sondagem Linear

Exemplo:

- Considere-se uma função de *hash* $H(N,M)=N\%M$.

Insere(89);
Insere(18);
Insere(49);
Insere(58);
Insere(9);

0	
1	
2	
3	
4	
5	
6	
7	
8	
9	



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

→ Insere(89); $H(89,10)=9$
Insere(18);
Insere(49);
Insere(58);
Insere(9);

0	
1	
2	
3	
4	
5	
6	
7	
8	
9	



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

→ Insere(89); $H(89,10)=9$
Insere(18);
Insere(49);
Insere(58);
Insere(9);

0	
1	
2	
3	
4	
5	
6	
7	
8	
9	89



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

→ Insere(89);
Insere(18); $H(18,10)=8$
Insere(49);
Insere(58);
Insere(9);

0	
1	
2	
3	
4	
5	
6	
7	
8	
9	89



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Inserere(89);

→ Inserere(18); $H(18,10)=8$

Inserere(49);

Inserere(58);

Inserere(9);

0	
1	
2	
3	
4	
5	
6	
7	
8	8
9	89



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Insere(89);

Insere(18);

→ Insere(49); $H(49,10)=9$

Insere(58); **Colisão!**

Insere(9);

0	
1	
2	
3	
4	
5	
6	
7	
8	8
9	89



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Insere(89);

Insere(18);

Insere(49); $H(49,10)=9$

Insere(58);

Insere(9);

Vamos
pesquisar a
próxima
posição livre!

0	
1	
2	
3	
4	
5	
6	
7	
8	8
9	89



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

→ Insere(89);
Insere(18);
→ Insere(49); $H(49,10)=9$
Insere(58); **Aqui.**
Insere(9);

→ 0	
1	
2	
3	
4	
5	
6	
7	
8	8
9	89



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Insere(89);

Insere(18);

→ Insere(49); $H(49,10)=9$

Insere(58);

Aqui.

Insere(9);

0	49
1	
2	
3	
4	
5	
6	
7	
8	8
9	89



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Inserere(89);

Inserere(18);

Inserere(49);

→ Inserere(58); $H(58,10)=8$

Inserere(9); **Colisão!**

0	49
1	
2	
3	
4	
5	
6	
7	
8	8
9	89



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Inserere(89);

Inserere(18);

Inserere(49);

→ Inserere(58); $H(58,10)=8$

Inserere(9); sondagem linear...

0	49
1	
2	
3	
4	
5	
6	
7	
8	8
9	89



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Insere(89);

Insere(18);

Insere(49);

→ Insere(58); $H(58,10)=8$

Insere(9); sondagem linear...

0	49
1	
2	
3	
4	
5	
6	
7	
8	8
9	89



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

		0	49
		1	
		2	
		3	
		4	
		5	
		6	
		7	
		8	8
		9	89

Insere(89);
Insere(18);
Insere(49);
 Insere(58); $H(58,10)=8$
Insere(9); sondagem linear...



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Insere(89);
Insere(18);
Insere(49);
→ Insere(58); $H(58,10)=8$
Insere(9); Aqui...


0	49
1	
2	
3	
4	
5	
6	
7	
8	8
9	89



Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Insere(89);
Insere(18);
Insere(49);
→ Insere(58); $H(58,10)=8$
Insere(9); Aqui...



0	49
1	58
2	
3	
4	
5	
6	
7	
8	8
9	89




Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Insere(89);
Insere(18);
Insere(49);
Insere(58);
→ Insere(9); $H(9,10)=9$

Após pesquisa...

0	49
1	58
2	
3	
4	
5	
6	
7	
8	8
9	89




Colisões - Sondagem Linear

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Insere(89);
Insere(18);
Insere(49);
Insere(58);
→ Insere(9); $H(9,10)=9$

Após pesquisa...

0	49
1	58
2	9
3	
4	
5	
6	
7	
8	8
9	89



Colisões - Sondagem Linear

- Desde que a tabela não esteja cheia, será sempre encontrada uma célula livre.
- Se a tabela estiver muito cheia, poderá ser necessário percorrer muitos elementos
 - Em média, para uma tabela perto da capacidade máxima, será necessário percorrer cerca de $N/2$ elementos.
 - O que está bastante longe do tempo constante pretendido.
- No entanto, caso a tabela se mantenha relativamente desocupada, os resultados são bons.



Colisões - Sondagem Linear

- Análise:
 - Caso a ocupação de células seja independente, o número de células percorrido pela sondagem linear é dado por:

$$1/(1-\lambda)$$

onde λ é a taxa de ocupação da tabela.

- No entanto, a ocupação das células não é independente....
 - Costumam formar-se *clusters* de células.
 - Este valor dá-nos por isso apenas uma indicação do desempenho máximo, em condições perfeitamente ideais.



Colisões - Sondagem Linear

- **Análise:**
 - O efeito de *clustering* faz com na prática o número de células médio analisado seja dado por:

$$\frac{1}{2} \left(1 + \frac{1}{(1 - \lambda)^2} \right)$$

taxa de ocupação	# células
0	1,0
0,1	1,1
0,2	1,3
0,3	1,5
0,4	1,9
0,5	2,5
0,6	3,6
0,7	6,1
0,8	13,0
0,9	50,5



Colisões - Sondagem Linear

- **Análise (Pesquisa):**

- O custo de uma pesquisa sem sucesso é idêntico ao custo da inserção mediante a taxa de ocupação actual.
- O custo de uma pesquisa com sucesso é idêntico ao custo da inserção mediante a taxa de ocupação quando esse valor foi inserido. É por isso menor.
 - Sabendo isso, calculando o valor médio, verifica-se que o número de células percorrido em média por uma pesquisa com sucesso é dado por:

$$\frac{1}{2} \left(1 + \frac{1}{1 - \lambda} \right)$$

taxa de ocupação	# células
0	1,0
0,1	1,1
0,2	1,1
0,3	1,2
0,4	1,3
0,5	1,5
0,6	1,8
0,7	2,2
0,8	3,0
0,9	5,5



Sondagem Quadrática

- A sondagem linear funciona muito bem para taxas de ocupação reduzidas
 - Os problema de desempenho para taxas de ocupação elevada são causados por *clustering* dos dados.
- Métodos alternativos propõem melhorar esse aspecto sem aumentar a complexidade do algoritmo.
- Um desses algoritmos é a sondagem quadrática
 - A ideia base é efectuar a pesquisa de forma não sequencial de forma a evitar a agregação de itens de dados





sondagem quadrática

- Caso a posição H esteja ocupada:
 - Pesquisa Sequencial:
 - Procura-se nas posições: $H+1, H+2, H+3, \dots$
 - sondagem quadrática:
 - Procura-se nas posições: $H+1^2, H+2^2, H+3^2, \dots$




sondagem quadrática

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Inserere(89);

Inserere(18);

 Inserere(49); $H(49,10)=9$

Inserere(58); **Colisão!**

Inserere(9);

0	
1	
2	
3	
4	
5	
6	
7	
8	18
9	89



sondagem quadrática

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

$$(9+1^2) \bmod 10 = 0$$



0

1

2

3

4

5

6

7

8

9

18	
89	

Inserere(89);

Inserere(18);

Inserere(49); $H(49,10)=9$

Inserere(58);

Inserere(9);



sondagem quadrática

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

$$(9+1^2) \bmod 10 = 0$$



0	49
1	
2	
3	
4	
5	
6	
7	
8	8
9	89

Inserere(89);

Inserere(18);

Inserere(49); $H(49,10)=9$

Inserere(58);

Inserere(9);



sondagem quadrática

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

Inserere(89);

Inserere(18);

Inserere(49);

→ Inserere(58); $H(58,10)=8$

Inserere(9);

$$(8+1^2) \bmod 10 = 9$$



0	49
1	
2	
3	
4	
5	
6	
7	
8	8
9	89



sondagem quadrática

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

$(8+2^2) \bmod 10 = 2$

→

Insere(89);
Insere(18);
Insere(49);
→ Insere(58); $H(58,10)=8$
Insere(9);

0	49
1	
2	
3	
4	
5	
6	
7	
8	8
9	89



sondagem quadrática

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

$(8+2^2) \bmod 10 = 2$

Insere(89);
Insere(18);
Insere(49);
→ Insere(58); $H(58,10)=8$
Insere(9);

0	49
1	
2	58
3	
4	
5	
6	
7	
8	8
9	89



sondagem quadrática

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

$$(9+1^2) \bmod 10 = 0$$



0	49
1	
2	58
3	
4	
5	
6	
7	
8	8
9	89

Inserir(89);

Inserir(18);

Inserir(49);

Inserir(58);

Inserir(9); $H(9,10)=9$



sondagem quadrática

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

→

Inserere(89);
Inserere(18);
Inserere(49);
Inserere(58);
Inserere(9); *$H(9,10)=9$*

$(9+2^2) \bmod 10 = 3$

→

0	49
1	
2	58
3	
4	
5	
6	
7	
8	8
9	89



sondagem quadrática

- Exemplo:
 - Considere-se uma função de *hash* $H(N,M)=N\%M$.

→

Inserere(89);
Inserere(18);
Inserere(49);
Inserere(58);
Inserere(9);

$H(9,10)=9$

$(9+2^2) \bmod 10 = 3$

→

0	49
1	
2	58
3	9
4	
5	
6	
7	
8	8
9	89



sondagem quadrática

- Será que funciona mesmo?
 - Percorremos todas as células?
 - Se existir apenas uma célula livre, conseguimos encontrá-la?
 - Passamos por cada célula uma única vez?



sondagem quadrática

- Será que funciona mesmo?
 - Percorreremos todas as células?
 - Se existir apenas uma célula livre, conseguimos encontrá-la?
 - Passamos por cada célula uma única vez?

Sim, se a dimensão da tabela for prima e a carga menor do que 0.5



sondagem quadrática

- Eliminando os *clusters*, temos um ganho potencial de 0.5 acessos quando a taxa de ocupação é de 0.5
 - 2 (ideal) vs. 2.5(p.linear)
- O ganho é muito reduzido:
 - Dado que a implementação parece necessitar um uma multiplicação, uma soma e o cálculo do resto, será que vale mesmo a pena?...



sondagem quadrática

- Implementação:
 - Felizmente, a implementação da sondagem quadrática é mais simples do que aparenta ser...
 - Se H_{i-1} for a última posição calculada e pretende-se calcular H_i (H_0 é a pos. original), então:

$$H_i = H_0 + i^2$$

$$H_{i-1} = H_0 + (i-1)^2$$

Sabendo isso e subtraindo...



sondagem quadrática

- Implementação:

O índice pode ser calculado a partir de:

$$H_i = H_{i-1} + (2i-1)(\text{mod } M)$$

Como $2i-1$ é menor do que M (porquê?), a operação *mod* pode ser efectuada com um teste e subtracção (como?)



Redimensionamento

- A *hash table* pode ser redimensionada quando atinge uma taxa de ocupação de 0.5:
 - Para melhor o desempenho, no caso da sondagem linear.
 - Tipicamente, o tamanho é aumentado para o dobro
 - Para garantir operação correcta, no caso da sondagem quadrática
 - Neste caso, é necessário encontrar o próximo número primo maior do que o dobro do tamanho actual:
 - Esta operação demora $O(N^{1/2} \log N)$. (menor que $O(N)$)



Redimensionamento

- Será possível simplesmente copiar os items para a nova tabela?



Redimensionamento

- Será possível simplesmente copiar os items para a nova tabela?
 - Não: a função de *hash* depende da dimensão da tabela
 - É necessário recalcular de novo os valores de *hash* e reintroduzir a informação.
 - Esta operação chama-se *rehashing*.




Encadeamento

- As técnicas de sondagem não funcionam bem para taxas de ocupação elevadas.
 - Obrigam por isso ao redimensionamento das tabelas.
- Caso o redimensionamento seja indesejável, é possível usar a técnica de *encadeamento* para lidar com colisões.



Encadeamento

- Neste caso, em cada posição da tabela, há uma lista que contém todos os elementos que partilham esse índice *hash*.



Encadeamento

- No caso de encadeamento, a taxa de ocupação pode ser maior do que 1.
 - O comprimento médio das listas é igual à taxa de ocupação λ .
 - O número médio de células percorridas para inserção é λ
 - O número médio de células percorridas para uma pesquisa com sucesso é $1 + \lambda/2$
 - A taxa de carga típica é 1.0



